

LAPORAN
ANALITIK DAN VISUALISASI DATA
ANALISIS FAKTOR-FAKTOR YANG MEMPENGARUHI
BIAYA ASURANSI KESEHATAN



Disusun oleh:

Hanif Amelia Putri (2509116075)

Program Studi Sistem Informasi

Fakultas Teknik

Universitas Mulawarman

2026

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas limpahan rahmat dan karunia-Nya sehingga laporan Ujian Tengah Semester (UTS) mata kuliah Analitik dan Visualisasi Data yang berjudul “Analisis Faktor-Faktor yang Mempengaruhi Biaya Asuransi Kesehatan” ini dapat diselesaikan dengan baik dan tepat waktu.

Laporan ini disusun sebagai salah satu pemenuhan tugas UTS pada Program Studi Sistem Informasi, Fakultas Teknik, Universitas Mulawarman. Dalam laporan ini, penulis melakukan analisis terhadap dataset Medical Insurance Cost untuk mengidentifikasi faktor-faktor yang memengaruhi besarnya biaya asuransi kesehatan, serta menyajikan hasil analisis tersebut melalui visualisasi data yang informatif.

Penulis menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun dari berbagai pihak demi perbaikan dan peningkatan kualitas laporan di masa mendatang. Semoga laporan ini dapat memberikan manfaat bagi pembaca, khususnya dalam memahami penerapan analisis dan visualisasi data pada bidang asuransi kesehatan.

Penulis

DAFTAR ISI

KATA PENGANTAR.....	ii
DAFTAR ISI.....	iii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Tujuan Analisis	2
BAB II PEMBAHASAN.....	3
2.1 Business Understanding	3
2.1.1 Business Objective	3
2.1.2 Assess Situation	3
2.1.3 Analytic Goals / Project Plan	4
2.2 Data Understanding.....	5
2.2.1 Memuat Dataset	5
2.2.2 Melihat Informasi Dataset.....	6
2.2.3 Melihat Statistik Deskriptif Data	7
2.2.4 Melihat Tipe Data pada Dataset.....	8
2.2.5 Pengecekan Inconsistent Value.....	9
2.2.6 Pengecekan Missing Values.....	13
2.2.7 Pengecekan Duplicated Values	14
2.2.8 Pengecekan Outliers Values.....	14
2.3 Exploratory Data Analysis (EDA)	16
2.3.1 Comparison (Perbandingan)	17
2.3.2 Composition (Komposisi)	18
2.3.4 Distribution (Distribusi).....	19
2.3.5 Relationship (Hubungan)	20
BAB III PENUTUP	22

3.1 Kesimpulan	22
----------------------	----

DAFTAR GAMBAR

Gambar 2.1 <i>Dataset Medical Asurance Cost</i>	6
Gambar 2.2 Informasi Dataset	7
Gambar 2.3 <i>Output Statistik Dataset Menggunakan Fungsi Describe</i>	8
Gambar 2.4 <i>Output Tipe Data</i>	9
Gambar 2.5 <i>Output Variabel Sex</i>	9
Gambar 2.6 <i>Output Variabel Smoker</i>	10
Gambar 2.7 <i>Output Variabel Region</i>	10
Gambar 2.8 <i>Output Variabel BMI</i>	11
Gambar 2.9 <i>Output Variabel Children</i>	12
Gambar 2.10 <i>Output Variabel Charges</i>	12
Gambar 2.11 Pengecekan Variabel <i>Age</i>	13
Gambar 2.12 Pengecekan <i>Missing Values</i>	14
Gambar 2.13 Pengecekan <i>Duplicated Values</i>	14
Gambar 2.14 Pengecekan <i>Outlaers Values</i>	15
Gambar 2.15 <i>Comparison</i> (Perbandingan)	17
Gambar 2.16 <i>Composition</i> (Komposisi)	18
Gambar 2.17 <i>Distribution</i> (Distribusi)	19
Gambar 2.18 <i>Relationship</i> (Hubungan)	20

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan analisis data saat ini telah memberikan dampak yang signifikan dalam berbagai bidang, termasuk dalam sektor kesehatan dan industri asuransi. Pemanfaatan data memungkinkan organisasi untuk memahami pola tertentu serta menghasilkan informasi yang dapat digunakan sebagai dasar dalam pengambilan keputusan yang lebih tepat. Dalam industri asuransi kesehatan, analisis data menjadi sangat penting untuk membantu perusahaan memahami faktor-faktor yang mempengaruhi besarnya biaya asuransi yang harus dibayarkan oleh pelanggan.

Asuransi kesehatan merupakan salah satu bentuk perlindungan finansial yang bertujuan untuk membantu masyarakat dalam menghadapi risiko biaya pengobatan akibat penyakit atau kecelakaan. Dengan adanya asuransi kesehatan, masyarakat dapat memperoleh jaminan terhadap biaya pelayanan kesehatan yang diperlukan sehingga dapat mengurangi beban finansial yang mungkin timbul. Keberadaan asuransi kesehatan juga menjadi bagian penting dalam sistem pelayanan kesehatan karena dapat meningkatkan akses masyarakat terhadap layanan kesehatan yang lebih baik.

Dalam praktiknya, besarnya biaya asuransi kesehatan tidak ditentukan secara acak, melainkan dipengaruhi oleh berbagai faktor yang berkaitan dengan karakteristik individu. Beberapa faktor yang sering dikaji dalam penelitian terkait biaya kesehatan antara lain usia, jenis kelamin, indeks massa tubuh (BMI), jumlah tanggungan keluarga, kebiasaan merokok, serta wilayah tempat tinggal. Faktor-faktor tersebut dapat mempengaruhi tingkat risiko kesehatan seseorang sehingga berdampak pada besarnya biaya yang harus ditanggung oleh pihak asuransi.

Selain itu, penelitian sebelumnya juga menunjukkan bahwa berbagai karakteristik pasien dan kondisi kesehatan dapat mempengaruhi besarnya biaya pelayanan kesehatan yang harus dikeluarkan. Analisis terhadap faktor-faktor tersebut penting dilakukan agar sistem pembiayaan kesehatan dapat dikelola secara lebih efektif dan efisien.

Berdasarkan hal tersebut, analisis data diperlukan untuk memahami hubungan antara berbagai faktor yang mempengaruhi biaya asuransi kesehatan. Dengan memanfaatkan teknik eksplorasi data dan visualisasi data, pola-pola yang terdapat

dalam data dapat dianalisis secara lebih jelas sehingga menghasilkan insight yang dapat mendukung pengambilan keputusan. Pada penelitian ini dilakukan analisis terhadap dataset Medical Insurance Cost untuk mengidentifikasi faktor-faktor yang mempengaruhi biaya asuransi kesehatan serta menyajikan hasil analisis dalam bentuk visualisasi data dan dashboard interaktif.

1.2 Tujuan Analisis

Bagian ini berisi tujuan yang ingin dicapai dari analisis yang dilakukan. Tujuan ditulis dengan jelas dan langsung ke inti.

1. Mengidentifikasi faktor-faktor yang mempengaruhi biaya asuransi kesehatan, seperti usia, jenis kelamin, indeks massa tubuh (BMI), jumlah anak, status merokok, dan wilayah tempat tinggal.
2. Menganalisis hubungan antara variabel-variabel tersebut dengan biaya asuransi kesehatan yang harus dibayarkan.

BAB II

PEMBAHASAN

2.1 Business Understanding

2.1.1 Business Objective

Dataset yang digunakan dalam penelitian ini adalah Medical Insurance Cost Dataset, yang berisi data mengenai biaya asuransi kesehatan dari 1338 individu. Dataset ini memuat beberapa variabel yang menggambarkan karakteristik pelanggan asuransi, antara lain usia (*age*), jenis kelamin (*sex*), indeks massa tubuh (*bmi*), jumlah anak (*children*), status merokok (*smoker*), wilayah tempat tinggal (*region*), serta biaya asuransi kesehatan (*charges*).

Data tersebut mencerminkan variasi kondisi individu yang berbeda-beda pada setiap pelanggan. Perbedaan karakteristik tersebut berpotensi mempengaruhi tingkat risiko kesehatan seseorang, yang pada akhirnya dapat berdampak pada besarnya biaya asuransi yang harus dibayarkan. Oleh karena itu, dataset ini dapat digunakan untuk menganalisis hubungan antara karakteristik pelanggan dengan biaya asuransi kesehatan.

Permasalahan bisnis yang dihadapi oleh perusahaan asuransi adalah bagaimana menentukan premi asuransi yang adil dan sesuai dengan tingkat risiko pelanggan. Setiap individu memiliki karakteristik yang berbeda sehingga biaya klaim asuransi yang mungkin terjadi juga dapat berbeda secara signifikan. Jika perusahaan tidak memahami faktor-faktor yang mempengaruhi besarnya biaya asuransi, maka penetapan premi berpotensi menjadi tidak akurat.

Melalui analisis pada dataset Medical Insurance Cost, perusahaan asuransi diharapkan dapat memahami faktor-faktor yang memiliki pengaruh terhadap besarnya biaya asuransi kesehatan. Hasil analisis ini dapat memberikan insight mengenai variabel mana yang memberikan pengaruh signifikan terhadap peningkatan biaya asuransi. Informasi tersebut dapat dimanfaatkan oleh perusahaan sebagai dasar dalam menentukan premi yang lebih tepat, adil, serta sesuai dengan tingkat risiko masing-masing pelanggan.

2.1.2 Assess Situation

Situasi bisnis yang mendasari analisis ini adalah meningkatnya biaya layanan kesehatan yang secara langsung berdampak pada besarnya klaim asuransi yang harus

ditanggung oleh perusahaan. Oleh karena itu, perusahaan asuransi perlu memastikan bahwa premi yang ditetapkan kepada pelanggan sudah sesuai dengan tingkat risiko yang dimiliki oleh masing-masing individu.

Apabila premi yang ditetapkan terlalu rendah, perusahaan berpotensi mengalami kerugian karena biaya klaim yang harus dibayarkan lebih besar dari pendapatan premi. Sebaliknya, apabila premi yang ditetapkan terlalu tinggi, pelanggan dapat merasa terbebani sehingga berpotensi menurunkan minat masyarakat untuk menggunakan layanan asuransi tersebut.

Dataset yang digunakan dalam analisis ini berisi 1338 data individu dengan berbagai karakteristik, seperti usia, jenis kelamin, indeks massa tubuh (BMI), jumlah anak, status merokok, serta wilayah tempat tinggal. Variasi karakteristik tersebut menunjukkan bahwa setiap individu memiliki tingkat risiko kesehatan yang berbeda-beda. Perbedaan tingkat risiko ini dapat menyebabkan variasi biaya asuransi yang cukup signifikan antar pelanggan.

Meskipun dataset telah tersedia dalam bentuk digital, terdapat beberapa tantangan yang perlu diperhatikan dalam proses analisis data. Salah satu tantangan yang ditemukan adalah rentang nilai biaya asuransi (*charges*) yang cukup besar, yang menunjukkan kemungkinan adanya distribusi data yang tidak merata atau keberadaan nilai ekstrem (*outlier*). Nilai ekstrem tersebut dapat mempengaruhi hasil analisis apabila tidak ditangani dengan tepat.

Selain itu, beberapa variabel dalam dataset merupakan variabel kategorikal, seperti jenis kelamin (*sex*), wilayah (*region*), dan status merokok (*smoker*). Variabel-variabel tersebut perlu diolah terlebih dahulu sebelum digunakan dalam proses analisis data. Oleh karena itu, diperlukan proses analisis data yang sistematis untuk memahami pola biaya asuransi, mengidentifikasi faktor-faktor yang paling berpengaruh, serta mendukung proses penetapan premi yang lebih akurat dan berbasis data.

2.1.3 Analytic Goals / Project Plan

Berdasarkan permasalahan yang telah diidentifikasi sebelumnya, maka tujuan analisis dalam proyek ini adalah untuk memahami hubungan antara karakteristik individu dengan biaya asuransi kesehatan. Analisis dilakukan dengan memanfaatkan teknik eksplorasi data dan visualisasi data untuk menemukan pola yang terdapat dalam dataset.

Beberapa langkah analisis yang dilakukan dalam proyek ini antara lain sebagai berikut:

1. Mengidentifikasi faktor-faktor yang mempengaruhi besarnya biaya asuransi kesehatan berdasarkan karakteristik individu yang terdapat dalam dataset.
2. Menganalisis hubungan antara variabel seperti usia, indeks massa tubuh (BMI), jumlah anak, serta kebiasaan merokok terhadap besarnya biaya asuransi yang harus dibayarkan oleh pelanggan.
3. Membuat visualisasi data untuk membantu memahami pola distribusi data serta hubungan antar variabel yang terdapat dalam dataset.
4. Menyusun dashboard interaktif yang dapat digunakan untuk mengeksplorasi data dan mempermudah pemahaman terhadap hasil analisis.
5. Memberikan rekomendasi berbasis data yang dapat membantu perusahaan asuransi dalam menentukan premi yang lebih akurat serta sesuai dengan tingkat risiko pelanggan.

2.2 Data Understanding

Dataset yang digunakan dalam analisis ini adalah Medical Insurance Cost Dataset yang berisi informasi mengenai karakteristik individu serta biaya asuransi kesehatan. Dataset ini terdiri dari 1338 data individu dengan beberapa variabel yang menggambarkan kondisi masing-masing pelanggan. Variabel yang terdapat dalam dataset antara lain age yang menunjukkan usia individu, sex yang menunjukkan jenis kelamin, bmi yang merupakan indeks massa tubuh (*Body Mass Index*), children yang menunjukkan jumlah anak yang ditanggung oleh individu tersebut, smoker yang menunjukkan status merokok, region yang menunjukkan wilayah tempat tinggal, serta charges yang menunjukkan biaya asuransi kesehatan yang harus dibayarkan oleh individu.

2.2.1 Memuat Dataset

```
import pandas as pd

file = "/content/drive/MyDrive/AVD/insurance.csv"
df = pd.read_csv(file)
df
```

Kode program di atas digunakan untuk membaca dataset yang tersimpan dalam format CSV. Library Pandas diimpor terlebih dahulu untuk memudahkan proses pengolahan data. Variabel file digunakan untuk menyimpan lokasi atau path dari dataset yang berada di Google Drive. Selanjutnya fungsi `pd.read_csv()` digunakan untuk membaca file dataset dan menyimpannya ke dalam sebuah DataFrame bernama

df. DataFrame merupakan struktur data berbentuk tabel yang memudahkan proses analisis data. Output dari kode tersebut menampilkan seluruh isi dataset yang berisi informasi mengenai usia, jenis kelamin, indeks massa tubuh (BMI), jumlah anak, status merokok, wilayah tempat tinggal, serta biaya asuransi kesehatan.

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
1	18	male	33.770	1	no	southeast	1725.55230
2	28	male	33.000	3	no	southeast	4449.46200
3	33	male	22.705	0	no	northwest	21984.47061
4	32	male	28.880	0	no	northwest	3866.85520
...	...	...	...	...	...	...	...
1333	50	male	30.970	3	no	northwest	10600.54830
1334	18	female	31.920	0	no	northeast	2205.98080
1335	18	female	36.850	0	no	southeast	1629.83350
1336	21	female	25.800	0	no	southwest	2007.94500
1337	61	female	29.070	0	yes	northwest	29141.36030

1338 rows × 7 columns

Gambar 2.1 *Dataset Medical Asurance Cost*

2.2.2 Melihat Informasi Dataset

Setelah dataset berhasil dimuat, langkah selanjutnya adalah melihat informasi umum dari dataset seperti jumlah data dan tipe data pada setiap variabel.

```
df.info()
```

Kode tersebut digunakan untuk menampilkan informasi mengenai jumlah baris data, jumlah kolom, serta tipe data yang terdapat pada setiap variabel. Informasi ini penting untuk mengetahui apakah tipe data pada setiap kolom sudah sesuai dengan kebutuhan analisis. Output dari perintah ini menunjukkan bahwa dataset memiliki 1338 baris data dan terdiri dari beberapa tipe data seperti integer, float, dan object.

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1338 entries, 0 to 1337
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   age         1338 non-null   int64
1   sex         1338 non-null   object
2   bmi         1338 non-null   float64
3   children    1338 non-null   int64
4   smoker      1338 non-null   object
5   region      1338 non-null   object
6   charges     1338 non-null   float64
dtypes: float64(2), int64(2), object(3)
memory usage: 73.3+ KB
```

Gambar 2.2 Informasi Dataset

2.2.3 Melihat Statistik Deskriptif Data

Selanjutnya dilakukan analisis statistik deskriptif untuk mengetahui gambaran umum dari variabel numerik yang terdapat dalam dataset.

```
df.describe(include='all')
```

Fungsi `describe()` digunakan untuk menampilkan statistik dasar seperti nilai rata-rata (*mean*), nilai minimum (*min*), nilai maksimum (*max*), serta nilai kuartil dari setiap variabel numerik. Informasi ini membantu dalam memahami distribusi data serta mengidentifikasi kemungkinan adanya nilai yang tidak wajar.

Output dari perintah tersebut menampilkan ringkasan statistik dari setiap variabel yang terdapat dalam dataset. Untuk variabel numerik seperti *age*, *bmi*, *children*, dan *charges*, ditampilkan informasi seperti jumlah data (*count*), nilai rata-rata (*mean*), standar deviasi (*std*), nilai minimum (*min*), nilai kuartil, serta nilai maksimum (*max*). Sementara itu, untuk variabel kategorikal seperti *sex*, *smoker*, dan *region*, ditampilkan informasi seperti jumlah data (*count*), jumlah kategori unik (*unique*), kategori yang paling sering muncul (*top*), serta frekuensi kemunculan kategori tersebut (*freq*). Informasi ini membantu dalam memahami karakteristik data secara keseluruhan sebelum dilakukan proses analisis lebih lanjut.

	age	sex	bmi	children	smoker	region	charges
count	1338.000000	1338	1338.000000	1338.000000	1338	1338	1338.000000
unique	NaN	2	NaN	NaN	2	4	NaN
top	NaN	male	NaN	NaN	no	southeast	NaN
freq	NaN	676	NaN	NaN	1064	364	NaN
mean	39.207025	NaN	30.663397	1.094918	NaN	NaN	13270.422265
std	14.049960	NaN	6.098187	1.205493	NaN	NaN	12110.011237
min	18.000000	NaN	15.960000	0.000000	NaN	NaN	1121.873900
25%	27.000000	NaN	26.296250	0.000000	NaN	NaN	4740.287150
50%	39.000000	NaN	30.400000	1.000000	NaN	NaN	9382.033000
75%	51.000000	NaN	34.693750	2.000000	NaN	NaN	16639.912515
max	64.000000	NaN	53.130000	5.000000	NaN	NaN	63770.428010

Gambar 2.3 Output Statistik Dataset Menggunakan Fungsi *Describe*

2.2.4 Melihat Tipe Data pada Dataset

Untuk mengetahui tipe data yang terdapat pada setiap variabel dalam dataset, digunakan fungsi `dtypes` pada `DataFrame`.

```
df.dtypes
```

Kode tersebut digunakan untuk menampilkan tipe data dari setiap kolom yang terdapat dalam dataset. Output dari perintah tersebut menunjukkan tipe data dari masing-masing variabel dalam dataset. Beberapa variabel seperti `age` dan `children` memiliki tipe data *integer* karena berisi angka bulat. Variabel `bmi` dan `charges` memiliki tipe data *float* karena berisi angka desimal. Sementara itu, variabel `sex`, `smoker`, dan `region` memiliki tipe data *object* yang menunjukkan bahwa data tersebut berupa kategori atau teks. Informasi mengenai tipe data ini penting untuk memastikan bahwa setiap variabel sudah memiliki format yang sesuai sebelum dilakukan proses analisis data lebih lanjut

```

0
age      int64
sex      object
bmi      float64
children int64
smoker   object
region   object
charges  float64
dtype: object

```

Gambar 2.4 Output Tipe Data

2.2.5 Pengecekan Inconsistent Value

Pada tahap ini dilakukan pengecekan terhadap kemungkinan adanya nilai yang tidak konsisten pada variabel kategorikal dalam dataset. Nilai yang tidak konsisten dapat terjadi karena perbedaan penulisan kategori, kesalahan pengetikan, atau penggunaan huruf besar dan kecil yang berbeda. Oleh karena itu, dilakukan pengecekan nilai unik pada setiap variabel kategorikal untuk memastikan bahwa data sudah konsisten sebelum dilakukan analisis lebih lanjut.

a. Pengecekan pada Variabel *Sex*

```
df['sex'].unique()
```

Kode tersebut digunakan untuk menampilkan seluruh nilai unik yang terdapat pada kolom *sex*. Output dari kode tersebut menunjukkan bahwa variabel *sex* hanya memiliki dua kategori yaitu *male* dan *female*. Hal ini menunjukkan bahwa tidak terdapat kesalahan penulisan atau nilai yang tidak konsisten pada variabel tersebut. Dengan demikian, data pada kolom *sex* sudah dapat digunakan dalam proses analisis.

```
['female' 'male']
```

Gambar 2.5 Output Variabel *Sex*

b. Pengecekan pada Variabel *Smoker*

Selanjutnya dilakukan pengecekan nilai unik pada variabel **smoker** untuk memastikan bahwa kategori status merokok tidak memiliki penulisan yang berbeda.

```
df['smoker'].unique()
```

Kode tersebut digunakan untuk menampilkan nilai unik yang terdapat pada variabel smoker. Hasil output menunjukkan bahwa variabel smoker memiliki dua kategori yaitu yes dan no. Hal ini menunjukkan bahwa data pada variabel tersebut sudah konsisten dan tidak ditemukan kesalahan penulisan kategori. Dengan demikian, variabel smoker dapat langsung digunakan dalam proses analisis data.

```
['yes' 'no']
```

Gambar 2.6 *Output Variabel Smoker*

c. Pengecekan pada Variabel Region

Pengecekan juga dilakukan pada variabel region untuk mengetahui kategori wilayah yang terdapat dalam dataset.

```
df['region'].unique()
```

Kode tersebut digunakan untuk menampilkan seluruh kategori wilayah yang terdapat pada dataset. Output dari kode tersebut menunjukkan bahwa variabel region memiliki empat kategori wilayah yaitu southwest, southeast, northwest, dan northeast. Berdasarkan hasil pengecekan tersebut dapat disimpulkan bahwa tidak terdapat nilai yang tidak konsisten pada variabel region. Data pada variabel ini sudah memiliki kategori yang jelas dan siap digunakan untuk proses analisis lebih lanjut.

```
['southwest' 'southeast' 'northwest' 'northeast']
```

Gambar 2.7 *Output Variabel Region*

d. Pengecekan pada Variabel BMI

Selain variabel kategorikal, dilakukan juga pengecekan terhadap nilai pada variabel BMI untuk melihat variasi nilai yang terdapat dalam dataset.

```
df['region'].unique()
```

Kode tersebut digunakan untuk menampilkan seluruh nilai unik yang terdapat pada variabel bmi dalam dataset. Output dari perintah tersebut menampilkan berbagai nilai indeks massa tubuh (*Body Mass Index*) yang dimiliki oleh setiap individu dalam dataset. Karena BMI merupakan variabel numerik, nilai yang muncul sangat beragam dan tidak terbatas pada kategori

tertentu. Variasi nilai ini menunjukkan perbedaan kondisi fisik masing-masing individu yang dapat mempengaruhi tingkat risiko kesehatan. Informasi ini penting untuk mengetahui rentang nilai BMI yang terdapat dalam dataset sebelum dilakukan analisis lebih lanjut.

```
[ 27.9  33.77 33.  22.705 28.88 25.74 33.44 27.74 29.83 25.84
26.22 26.29 34.4  39.82 42.13 24.6  30.78 23.845 40.3  35.3
36.005 32.4  34.1  31.92 28.025 27.72 23.085 32.775 17.385 36.3
35.6  26.315 28.6  28.31 36.4  20.425 32.965 20.8  36.67 39.9
26.6  36.63 21.78 30.8  37.05 37.3  38.665 34.77 24.53 35.2
35.625 33.63 28.  34.43 28.69 36.955 31.825 31.68 22.88 37.335
27.36 33.66 24.7  25.935 22.42 28.9  39.1  36.19 23.98 24.75
28.5  28.1  32.01 27.4  34.01 29.59 35.53 39.805 26.885 38.285
37.62 41.23 34.8  22.895 31.16 27.2  26.98 39.49 24.795 31.3
38.28 19.95 19.3  31.6  25.46 30.115 29.92 27.5  28.4  30.875
27.94 35.09 29.7  35.72 32.205 28.595 49.06 27.17 23.37 37.1
23.75 28.975 31.35 33.915 28.785 28.3  37.4  17.765 34.7  26.505
22.04 35.9  25.555 28.05 25.175 31.9  36.  32.49 25.3  29.735
38.83 30.495 37.73 37.43 24.13 37.145 39.52 24.42 27.83 36.85
39.6  29.8  29.64 28.215 37.  33.155 18.905 41.47 30.3  15.96
33.345 37.7  27.835 29.2  26.41 30.69 41.895 30.9  32.2  32.11
31.57 26.2  30.59 32.8  18.05 39.33 32.23 24.035 36.08 22.3
26.4  31.8  26.73 23.1  23.21 33.7  33.25 24.64 33.88 38.06
41.91 31.635 36.195 17.8  24.51 22.22 38.39 29.07 22.135 26.8
30.02 35.86 20.9  17.29 34.21 25.365 40.15 24.415 25.2  26.84
24.32 42.35 19.8  32.395 30.2  29.37 34.2  27.455 27.55 20.615
24.3  31.79 21.56 28.12 40.565 27.645 31.2  26.62 48.07 36.765
33.4  45.54 28.82 22.99 27.7  25.41 34.39 22.61 37.51 38.
33.33 34.865 33.06 35.97 31.4  25.27 40.945 34.105 36.48 33.8
36.7  36.385 34.5  32.3  27.6  29.26 35.75 23.18 25.6  35.245
43.89 20.79 30.5  21.7  21.89 24.985 32.015 30.4  21.09 22.23
32.9  24.89 31.46 17.955 30.685 43.34 39.05 30.21 31.445 19.855
31.02 38.17 20.6  47.52 20.4  38.38 24.31 23.6  21.12 30.03
17.48 20.235 17.195 23.9  35.15 35.64 22.6  39.16 27.265 29.165
16.815 33.1  26.9  33.11 31.73 46.75 29.45 32.68 33.5  43.01
36.52 26.695 25.65 29.6  38.6  23.4  46.53 30.14 30.  38.095
28.38 28.7  33.82 24.09 32.67 25.1  32.56 41.325 39.5  34.3
31.065 21.47 25.08 43.4  25.7  27.93 39.2  26.03 30.25 28.93
35.7  35.31 31.  44.22 26.07 25.8  39.425 40.48 38.9  47.41
35.435 46.7  46.2  21.4  23.8  44.77 32.12 29.1  37.29 43.12
36.06 34.295 23.465 45.43 23.65 20.7  28.27 35.91 29.  19.57
31.13 21.85 40.26 33.725 29.48 32.6  37.525 23.655 37.8  19.
21.3  33.535 42.46 38.95 36.1  29.3  39.7  38.19 42.4  34.96
42.68 31.54 29.81 21.375 40.81 17.4  20.3  18.5  26.125 41.69
24.1  36.2  40.185 39.27 34.87 44.745 29.545 23.54 40.47 40.66
36.6  35.4  27.075 28.405 21.755 40.28 30.1  32.1  23.7  35.5
29.15 27.  37.905 22.77 22.8  34.58 27.1  19.475 26.7  34.32
24.4  41.14 22.515 41.8  26.18 42.24 26.51 35.815 41.42 36.575
42.94 21.01 24.225 17.67 31.5  31.1  32.78 32.45 50.38 47.6
25.4  29.9  43.7  24.86 28.8  29.5  29.04 38.94 44.  20.045
40.92 35.1  29.355 32.585 32.34 39.8  24.605 33.99 28.2  25.
33.2  23.2  20.1  32.5  37.18 46.09 39.93 35.8  31.255 18.335
42.9  26.79 39.615 25.9  25.745 28.16 23.56 40.5  35.42 39.995
34.675 20.52 23.275 36.29 32.7  19.19 20.13 23.32 45.32 34.6
18.715 21.565 23.  37.07 52.58 42.655 21.66 32.  18.3  47.74
22.1  19.095 31.24 29.925 20.35 25.85 42.75 18.6  23.87 45.9
21.5  30.305 44.88 41.1  40.37 28.49 33.55 40.375 27.28 17.86
33.3  39.14 21.945 24.97 23.94 34.485 21.8  23.3  36.96 21.28
29.4  27.3  37.9  37.715 23.76 25.52 27.61 27.06 39.4  34.9
22.  30.36 27.8  53.13 39.71 32.87 44.7  30.97 ]
```

Gambar 2.8 Output Variabel BMI

e. Pengecekan pada Variabel Children

Selanjutnya dilakukan pengecekan terhadap nilai yang terdapat pada variabel children untuk mengetahui variasi jumlah anak yang dimiliki oleh individu dalam dataset.

```
df['children'].unique()
```


Kode tersebut digunakan untuk menampilkan seluruh nilai unik yang terdapat pada variabel `children` dalam dataset. Output dari perintah tersebut menunjukkan bahwa nilai pada variabel `children` terdiri dari 0, 1, 2, 3, 4. Nilai tersebut menunjukkan jumlah anak yang dimiliki oleh setiap individu dalam dataset. Hal ini menunjukkan bahwa individu dalam dataset memiliki jumlah tanggungan anak yang bervariasi, mulai dari tidak memiliki anak hingga memiliki lima anak. Variasi jumlah anak ini dapat menjadi salah satu faktor yang mempengaruhi besarnya biaya asuransi kesehatan yang harus dibayarkan oleh individu.

```
[0 1 3 2 5 4]
```

Gambar 2.9 *Output Variabel Children*

f. Pengecekan pada Variabel `Charges`

Selanjutnya dilakukan pengecekan nilai pada variabel `charges` untuk mengetahui variasi biaya asuransi kesehatan yang terdapat dalam dataset.

```
df['charges'].unique()
```

Kode tersebut digunakan untuk menampilkan seluruh nilai unik yang terdapat pada variabel `charges` dalam dataset. Output dari perintah tersebut menampilkan berbagai nilai biaya asuransi kesehatan yang dimiliki oleh setiap individu dalam dataset. Karena variabel `charges` merupakan variabel numerik, nilai yang muncul sangat beragam dan tidak terbatas pada kategori tertentu. Variasi nilai ini menunjukkan bahwa setiap individu memiliki biaya asuransi yang berbeda-beda. Perbedaan biaya tersebut dapat dipengaruhi oleh berbagai faktor seperti usia, indeks massa tubuh (BMI), jumlah anak, serta kebiasaan merokok. Informasi ini penting untuk memahami variasi biaya asuransi yang terdapat dalam dataset sebelum dilakukan analisis lebih lanjut.

```
[16884.924  1725.5523  4449.462  ...  1629.8335  2007.945  29141.3603]
```

Gambar 2.10 *Output Variabel Charges*

g. Pengecekan pada Variabel `Age`

Pengecekan juga dilakukan pada variabel `age` untuk mengetahui variasi usia yang terdapat dalam dataset.

```
df['age'].unique()
```

Kode tersebut digunakan untuk menampilkan seluruh nilai unik yang terdapat pada variabel *age* dalam dataset. Output dari perintah tersebut menunjukkan berbagai nilai usia yang terdapat pada dataset. Variabel *age* merupakan variabel numerik yang menunjukkan usia individu yang menjadi pelanggan asuransi kesehatan. Nilai usia dalam dataset bervariasi dari usia yang lebih muda hingga usia yang lebih tua. Variasi usia ini penting untuk dianalisis karena usia merupakan salah satu faktor yang dapat mempengaruhi tingkat risiko kesehatan serta besarnya biaya asuransi yang harus dibayarkan oleh individu.

```
[19 18 28 33 32 31 46 37 60 25 62 23 56 27 52 30 34 59 63 55 22 26 35 24
 41 38 36 21 48 40 58 53 43 64 20 61 44 57 29 45 54 49 47 51 42 50 39]
```

Gambar 2.11 Pengecekan Variabel *Age*

2.2.6 Pengecekan Missing Values

Pada tahap ini dilakukan pengecekan terhadap nilai yang hilang (missing values) pada dataset. Pengecekan ini penting dilakukan untuk mengetahui apakah terdapat data yang kosong pada setiap kolom yang dapat mempengaruhi hasil analisis.

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Kode tersebut digunakan untuk menghitung persentase nilai kosong pada setiap kolom dalam dataset. Fungsi *isna()* digunakan untuk mendeteksi nilai kosong, kemudian *sum()* digunakan untuk menghitung jumlahnya. Nilai tersebut kemudian dibagi dengan jumlah total data (*len(df)*) dan dikalikan 100 untuk mendapatkan persentase missing value pada setiap kolom. Berdasarkan hasil analisis, seluruh kolom yaitu *age*, *sex*, *bmi*, *children*, *smoker*, *region*, dan *charges* memiliki persentase missing value sebesar 0%. Hal ini menunjukkan bahwa tidak terdapat data yang kosong atau tidak terisi pada dataset. Dengan demikian, dataset sudah dalam kondisi lengkap dan tidak memerlukan proses penanganan missing value seperti penghapusan data maupun pengisian nilai tertentu.

Null Ratio in %	
age	0.0
sex	0.0
bmi	0.0
children	0.0
smoker	0.0
region	0.0
charges	0.0

Gambar 2.12 Pengecekan *Missing Values*

2.2.7 Pengecekan Duplicated Values

Selanjutnya dilakukan pengecekan terhadap kemungkinan adanya data duplikat pada dataset. Data duplikat merupakan baris data yang memiliki nilai yang sama persis dengan baris lainnya sehingga dapat mempengaruhi hasil analisis.

```
df[df.duplicated()]
```

Kode tersebut digunakan untuk menampilkan baris data yang memiliki nilai yang sama dengan baris lainnya pada dataset. Berdasarkan hasil pengecekan, ditemukan baris data yang terduplikasi pada dataset. Hal ini menunjukkan bahwa terdapat pengulangan data yang sama persis pada beberapa baris. Data duplikat seperti ini dapat mempengaruhi hasil analisis karena dapat menyebabkan data tertentu dihitung lebih dari satu kali. Oleh karena itu, data duplikat perlu diperhatikan dan dapat dihapus pada tahap data preparation agar analisis yang dilakukan menjadi lebih akurat.

	age	sex	bmi	children	smoker	region	charges
581	19	male	30.59	0	no	northwest	1639.5631

Gambar 2.13 Pengecekan *Duplicated Values*

2.2.8 Pengecekan Outliers Values

Pada tahap ini dilakukan pengecekan terhadap nilai ekstrem (outliers) pada kolom yang bertipe data numerik. Outliers merupakan nilai yang berada jauh di luar rentang mayoritas data sehingga dapat mempengaruhi hasil analisis.

Contoh kode program:

```
results = []

cols = df.select_dtypes(include=['float64', 'int64'])
```

```

for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

# Dataframe dari list hasil
results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

# Tampilkan dataframe
display(results_df)

```

Kode tersebut digunakan untuk menghitung persentase outliers pada setiap kolom numerik dalam dataset menggunakan metode Interquartile Range (IQR). Metode ini menghitung nilai kuartil pertama (Q1) dan kuartil ketiga (Q3), kemudian menentukan batas bawah dan batas atas untuk mendeteksi nilai yang berada di luar rentang tersebut.

Kolom	Persentase Outliers
age	0.000000
bmi	0.673149
children	0.000000
charges	10.396410

Gambar 2.14 Pengecekan *Outlaers Values*

Berdasarkan hasil analisis, diperoleh informasi bahwa kolom age dan children tidak memiliki outliers dengan persentase sebesar 0%. Sementara itu, kolom bmi memiliki outliers dalam jumlah kecil yaitu sebesar 0,67%. Kolom charges memiliki persentase outliers yang paling tinggi yaitu sebesar 10,39%. Hal ini menunjukkan bahwa terdapat beberapa nilai biaya asuransi yang jauh lebih tinggi dibandingkan dengan mayoritas data lainnya. Nilai ekstrem pada kolom charges ini dapat

memberikan gambaran bahwa terdapat individu dengan biaya asuransi yang sangat tinggi dibandingkan dengan rata-rata pelanggan lainnya.

Untuk melihat distribusi data serta mendeteksi keberadaan outliers secara visual, digunakan boxplot pada variabel charges.

```
plt.figure(figsize=(8, 6))
sns.boxplot(y=df['charges'])
plt.title('Boxplot of charges')
plt.ylabel('charges')
plt.show()
```

Kode tersebut digunakan untuk menampilkan visualisasi boxplot yang menunjukkan distribusi data pada variabel charges. Boxplot membantu dalam mengidentifikasi nilai median, kuartil, serta titik-titik yang berada di luar rentang normal yang menunjukkan adanya outliers. Output dari visualisasi boxplot menunjukkan bahwa terdapat beberapa titik data yang berada di luar rentang distribusi utama. Titik-titik tersebut merupakan outliers yang menunjukkan adanya nilai biaya asuransi yang jauh lebih tinggi dibandingkan mayoritas data lainnya. Visualisasi ini membantu dalam memahami penyebaran data serta mengidentifikasi nilai ekstrem yang terdapat pada variabel charges.

2.3 Exploratory Data Analysis (EDA)

Pada tahap Data Understanding, dilakukan pemahaman terhadap dataset yang digunakan dalam proses analisis. Dataset yang digunakan merupakan Medical Insurance Cost Dataset yang berisi 1338 data individu dengan beberapa variabel seperti age, sex, bmi, children, smoker, region, dan charges. Variabel-variabel tersebut menggambarkan karakteristik pelanggan asuransi kesehatan serta biaya asuransi yang harus dibayarkan.


Selanjutnya dilakukan Exploratory Data Analysis (EDA) untuk memahami pola data, distribusi nilai, serta hubungan antar variabel yang terdapat dalam dataset. Tahap ini bertujuan untuk memperoleh insight awal yang dapat membantu dalam proses analisis data selanjutnya. Pada tahap EDA dilakukan beberapa jenis analisis, yaitu comparison (perbandingan), composition (komposisi), distribution (distribusi), dan relationship (hubungan) antar variabel.

2.3.1 Comparison (Perbandingan)

Membandingkan rata-rata biaya asuransi (charges) berdasarkan status perokok (smoker). Tujuan dari analisis ini adalah untuk mengidentifikasi apakah terdapat perbedaan yang signifikan antara biaya asuransi peserta yang merokok dan yang tidak merokok.

Visualisasi yang digunakan adalah Bar Chart (Grafik Batang).

```
plt.figure(figsize=(8,5))
sns.barplot(x=charges_smoker.index,y=charges_smoker.values,palette='viridis',
hue=charges_smoker.index, legend=False)
plt.title('Rata-rata Charges Berdasarkan Status Perokok')
plt.xlabel('Smoker')
plt.ylabel('Rata-rata Charges')
plt.xticks(rotation=45)
plt.show()
```



Gambar 2.15 *Comparison* (Perbandingan)

Berdasarkan bar chart rata-rata charges berdasarkan status perokok, terlihat bahwa peserta yang merokok memiliki rata-rata biaya asuransi yang jauh lebih tinggi dibandingkan dengan peserta yang tidak merokok. Hal ini menunjukkan bahwa kebiasaan merokok memberikan dampak yang signifikan terhadap besarnya biaya asuransi kesehatan. Oleh karena itu, status merokok menjadi salah satu faktor penting dalam menentukan premi asuransi.

2.3.2 Composition (Komposisi)


Pada tahap ini dilakukan analisis terhadap proporsi peserta berdasarkan status perokok (smoker). Tujuan dari analisis ini adalah untuk mengetahui perbandingan jumlah peserta yang merokok dan yang tidak merokok dalam dataset.

Visualisasi yang digunakan adalah Pie Chart (Grafik Lingkaran).

```
smoker_count = df['smoker'].value_counts()

plt.figure(figsize=(8,8))
smoker_count.plot(kind='pie',
                  autopct='%1.1f%%',
                  startangle=140)

plt.title('Proporsi Peserta Berdasarkan Status Perokok')
plt.ylabel("")
plt.axis('equal')
plt.show()
```



Gambar 2.16 *Composition* (Komposisi)

Berdasarkan pie chart yang ditampilkan, terlihat bahwa sebagian besar peserta dalam dataset merupakan non-perokok, sedangkan peserta yang merokok hanya

sebagian kecil dari total keseluruhan peserta. Meskipun jumlah perokok lebih sedikit, kelompok ini tetap memberikan kontribusi yang cukup besar terhadap rata-rata biaya asuransi.


2.3.4 Distribution (Distribusi)

Tahap berikutnya adalah menganalisis penyebaran data biaya asuransi (charges). Tujuan dari analisis ini adalah untuk memahami pola distribusi data serta mengidentifikasi kemungkinan adanya nilai ekstrem atau ketimpangan dalam data.

Visualisasi yang digunakan adalah Histogram.

```
plt.figure(figsize=(10,6))
sns.histplot(df['charges'], bins=20, kde=True)

plt.title('Distribusi Biaya Asuransi (Charges)')
plt.xlabel('Charges')
plt.ylabel('Frekuensi')
plt.show()
```



Gambar 2.17 *Distribution (Distribusi)*

Berdasarkan histogram distribusi biaya asuransi, terlihat bahwa sebagian besar peserta memiliki biaya asuransi yang relatif rendah, sementara hanya sebagian kecil peserta yang memiliki biaya yang sangat tinggi. Distribusi data cenderung miring ke

kanan (right skewed) yang menunjukkan adanya beberapa peserta dengan biaya asuransi yang jauh lebih tinggi dibandingkan mayoritas peserta lainnya.


2.3.5 Relationship (Hubungan)

Analisis selanjutnya dilakukan untuk melihat hubungan antara nilai BMI dengan biaya asuransi (charges). Tujuan dari analisis ini adalah untuk mengetahui apakah peningkatan nilai BMI memiliki hubungan dengan peningkatan biaya asuransi kesehatan.

Visualisasi yang digunakan adalah Heatmap Korelasi.

```
plt.figure(figsize=(8,6))
sns.heatmap(data=df[['bmi','charges']].corr(),
            annot=True,
            cmap='viridis',
            fmt='.2f')

plt.title('Korelasi antara BMI dan Charges')
plt.show()
```



Gambar 2.18 Relationship (Hubungan)

Berdasarkan heatmap korelasi yang ditampilkan, terlihat bahwa terdapat hubungan positif antara BMI dan biaya asuransi, meskipun tingkat korelasinya tidak terlalu kuat. Hal ini menunjukkan bahwa peserta dengan BMI yang lebih tinggi cenderung memiliki biaya asuransi yang lebih tinggi. Namun demikian, faktor lain seperti usia, status merokok, serta kondisi kesehatan peserta juga turut mempengaruhi besarnya biaya asuransi.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan hasil analisis data dan visualisasi yang telah dilakukan, diperoleh beberapa temuan penting terkait faktor-faktor yang mempengaruhi biaya asuransi kesehatan. Hasil analisis menunjukkan bahwa usia peserta memiliki hubungan positif dengan biaya asuransi, dimana semakin bertambah usia seseorang maka biaya asuransi yang harus dibayarkan cenderung meningkat.

Selain itu, status merokok juga memiliki pengaruh yang signifikan terhadap biaya asuransi kesehatan. Peserta yang merokok cenderung memiliki biaya asuransi yang lebih tinggi dibandingkan dengan peserta yang tidak merokok. Hal ini menunjukkan bahwa kebiasaan merokok meningkatkan risiko kesehatan sehingga berdampak pada peningkatan biaya asuransi.

Selanjutnya, wilayah tempat tinggal peserta juga menunjukkan adanya perbedaan rata-rata biaya asuransi, dimana beberapa wilayah memiliki rata-rata biaya yang lebih tinggi dibandingkan wilayah lainnya. Selain faktor wilayah, kategori BMI juga berpengaruh terhadap total biaya asuransi, dimana peserta dengan kategori overweight dan obese cenderung memiliki biaya asuransi yang lebih besar dibandingkan peserta dengan BMI normal. Berdasarkan temuan tersebut dapat disimpulkan bahwa faktor usia, status merokok, wilayah tempat tinggal, dan kondisi BMI merupakan faktor penting yang mempengaruhi besarnya biaya asuransi kesehatan.